

UD6 – Almacenamiento de la información

LENGUAJES DE MARCAS Y SISTEMAS DE GESTIÓN DE LA
INFORMACIÓN

Introducción

Los datos contenidos en un documento XML no siempre analizan en el momento.

A veces se quiere guardar la información en un sistema de almacenamiento persistente para poder recuperarla y procesarla luego.

Como programadores, es algo que tenemos que decidir nosotros.

Hay varias alternativas.

Tipos de almacenami ento

1. Sin almacenamiento

Cuando se usa el formato XML solo como “vehículo” para portar la información.

En estos casos normalmente no hay necesidad de persistencia.

El XML está cargado en la memoria del programa.

Lo que sí hay que hacer es **convertir** de XML a otros formatos.



2. Almacenamiento en ficheros

Es el mecanismo más simple cuando necesitamos que la información sea persistente.

Es lo que hemos hecho durante todo el curso.

Ejemplo: fichero de configuración de arranque de un router.



3. Almacenamiento en BB.DD. relacionales

Las **bases de datos** son sistemas de almacenamiento...

- De información relacionada entre sí.
- Estructurados.
- Accesible digitalmente.

Diferentes tipos de bases de datos: relacionales, orientadas a objetos, en red, jerárquicas, etc.



3. Almacenamiento en BB.DD. relacionales

Las más comunes son las **bases de datos relacionales**.

Su principal objetivo no es alojar documentos estructurados como XML.


...no obstante permiten guardar ficheros de cualquier tipo.



3. Almacenamiento en BB.DD. relacionales

La solución para almacenar documentos XML en BB.DD. relacionales:

1. Crear una tabla.
2. Almacenar cada el documento XML en una columna (VARCHAR o BLOB, por ejemplo).
3. El documento se guarda/recupera haciendo un INSERT/SELECT en SQL.



id	nombre	xml
1	Librería La Cautiva	<?xml version="1.0" encoding="UTF-8" standalone="n...



3. Almacenamiento en BB.DD. relacionales

Ventajas:

- Podemos gestionar grandes volúmenes de información de manera más sencilla que con ficheros.
- Las BB.DD. relaciones están implantadas en todas las empresas, no hay que cambiar el software.

Desventajas:

- Engorroso: con SQL solo podemos extraer el documento completo. No podemos extraer información concreta del XML.
- Las BB.DD. relacionales son mucho más complejas que XML.



4. Almacenamiento en BB.DD. nativas

Las **bases de datos nativas XML** están orientadas al almacenamiento de documentos XML.

...frente a las bases de datos convencionales (relacionales), que están orientadas al almacenamiento de datos en tablas.

Nombre	Tipo de licencia
BaseX	Software libre - BSD
eXist-db	Software libre - LGPL
MarkLogic	Comercial
Qualcomm Qizx	Comercial



4. Almacenamiento en BB.DD. nativas

En una base de datos **relacional**:

- Tablas.
- Registros/tuplas.
- Atributos.
- Relaciones.
- ...



En una base de datos **XML**:

- Elementos.
- Atributos.
- Comentarios.
- Espacios de nombres.
- ...



4. Almacenamiento en BB.DD. nativas

Ventajas:

- Acceso a la información contenida sin necesidad de leer todo el documento.
- Más simples.

Desventajas:

- Hay que aprender nuevas técnicas de acceso, como el lenguaje Xpath o Xquery (“análogos” a SQL).
- Implica implementar nuevo software en nuestra empresa.



Xpath

Xpath – Introducción

Una de las operaciones más complejas de realizar sobre un documento XML es la búsqueda de información.

Para ello surgió **XPath**, un lenguaje que:


- Permite seleccionar nodos o conjuntos de nodos de un documento XML.
- Se utiliza como soporte para otras tecnologías (XQuery, XPointer, XSLT o XSL-FO).
- Es un estándar del W3C.

Xpath – Fundamentos

Un XML tiene una estructura árbol.

Xpath - Fundamentos

```
<?xml version="1.0" encoding="UTF-8"?>
<biblioteca>
  <libro>
    <titulo>La vida está en otra parte</titulo>
    <autor>Milan Kundera</autor>
    <fechaPublicacion año="1973"/>
  </libro>
  <libro>
    <titulo>Pantaleón y las visitadoras</titulo>
    <autor fechaNacimiento="28/03/1936">Mario
    Vargas Llosa</autor>
    <fechaPublicacion año="1973"/>
  </libro>
  <libro>
    <titulo>Conversación en la catedral</titulo>
    <autor fechaNacimiento="28/03/1936">Mario
    Vargas Llosa</autor>
    <fechaPublicacion año="1969"/>
  </libro>
</biblioteca>
```



Xpath – Fundamentos


Xpath se utiliza escribiendo **expresiones**.

Notación similar a la usada en el establecimiento de rutas en los sistemas de ficheros.

Ejemplo:

`/biblioteca/libro`

Devolvería todos los libros




Xpath – Tipos de nodos

En las expresiones es habitual seleccionar **nodos**.

Un nodo es cada elemento del árbol XML.

Existen 7:

- Raíz
- Elemento
- Atributo
- Texto
- Comentario, instrucciones de procesamiento y espacio de nombres.



Xpath – Tipos de nodos

Los elementos se indican por su nombre.

Los atributos, anteponiendo @ a su nombre.

Expresión	Resultado
/biblioteca/libro/autor	<autor>Milan Kundera</autor> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
/autor	No devuelve nada porque <autor> no es hijo del nodo raíz
/biblioteca/autor	No devuelve nada porque <autor> no es hijo de <biblioteca>.
/biblioteca/libro/autor/ @fechaNacimiento	fechaNacimiento="28/03/1936" fechaNacimiento="28/03/1936"

Ejes

Xpath – Ejes

La parte de una expresión Xpath que establece la ruta, es lo que se denomina **el eje** o **axis**.

Usamos operadores para escribir el eje:

Operador	Descripción
/	Permite establecer la ruta hasta el nodo que queremos.
//	Selecciona cualquier nodo que se encuentre en algún subnivel.
..	Selecciona el nodo padre.
	Permite varios recorridos
*	Todos los elementos debajo del nodo

Xpath - Eje /

Expresión	Resultado
/biblioteca/libro/autor	<autor>Milan Kundera</autor> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
/autor	No devuelve nada porque <autor> no es hijo del nodo raíz
/biblioteca/autor	No devuelve nada porque <autor> no es hijo de <biblioteca>.
/biblioteca/libro/autor/ @fechaNacimiento	fechaNacimiento="28/03/1936" fechaNacimiento="28/03/1936"

Xpath - Eje descendiente //

Expresión	Resultado
//autor	<autor>Milan Kundera</autor> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
//@fechaNacimiento	fechaNacimiento="28/03/1936" fechaNacimiento="28/03/1936"
/biblioteca//titulo	<titulo>La vida está en otra parte</titulo> <titulo>Pantaleón y las visitadoras</titulo> <titulo>Conversación en la catedral</titulo>

Xpath - Eje padre /..

Expresión	Resultado
<code>/biblioteca/libro/autor/ @fechaNacimiento/..</code>	<code><autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor></code>
<code>//@fechaNacimiento/.../..</code>	<code><libro> <titulo>Pantaleón y las visitadoras</titulo> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor> <fechaPublicacion año="1973"/> </libro> <libro> <titulo>Conversación en la catedral</titulo> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor> <fechaPublicacion año="1969"/> </libro></code>

Xpath - Eje |

Expresión	Resultado
<code>//autor //titulo</code>	<pre><titulo>La vida está en otra parte</titulo> <autor>Milan Kundera</autor> <titulo>Pantaleón y las visitadoras</titulo> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor> <titulo>Conversación en la catedral</titulo> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor></pre>
<code>//autor //titulo //@año</code>	<pre><titulo>La vida está en otra parte</titulo> <autor>Milan Kundera</autor> año="1973" <titulo>Pantaleón y las visitadoras</titulo> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor> año="1973" <titulo>Conversación en la catedral</titulo> <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor></pre>

Predicados

Xpath – Predicados

Los **predicados** se escriben entre corchetes `[]` a continuación del eje.

Permite restringir la selección.

Ejemplos:

Expresión	Resultado
<code>// autor[@fechaNacimiento]</code>	<code><autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor></code> <code><autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor></code>
<code>//libro[1]</code>	<code><libro></code> <code><titulo>La vida está en otra parte</titulo></code> <code><autor>Milan Kundera</autor></code> <code><fechaPublicacion año="1973"/></code> <code></libro></code>

Funciones

Xpath – Funciones

Xpath permite utilizar funciones tanto en los predicados como en los ejes.

Ejemplos:

```
//titulo/string()
```

```
//title/text()
```

```
//numero-trabajadores [data() > 16]
```

Ejemplos de referencia

XML de ejemplo

```
<?xml version="1.0" encoding="UTF-8"?>
<obras>
  <obra pais="Francia" anyo="1879">
    <titulo>Pont de Maincy</titulo>
    <autor>Paul Cézanne</autor>
    <museo visible="false" >Museo de Orsay</museo>
  </obra>
  <obra pais="España" anyo="1822" >
    <titulo>Alnalia de Llano</title>
    <autor>Federico de Madraza</autor>
    <museo visible="true">Museo del Prado</museo>
  </obra>
  <obra pais="Países Bajos" anyo="1890">
    <titulo>Trigal</title>
    <autor>Vincent Van Gogh</autor>
    <museo visible="true" >Museo Van Gogh</museo>
  </obra>
</obras>
```

Ejemplos para tratar **atributos**

Expresión	Resultado
//@*	Todos los atributos de todos los nodos.
//obra/@*	Todos los atributos de todos los nodos obra .
//obra/@pais	Atributo pais de todos los nodos obra .
//obra[@pais='Francia']	Todos los nodos obra cuyo atributo país tiene como valor 'Francia' .
//museo[@visible='true']/../titulo/text()	Todos los títulos (solo el texto) de aquellas obras que están en museos cuyo atributo visible tiene como valor true.

Funciones para **strings**

Función	Descripción
compare	Devuelve un valor numérico (-1, 0, 1) que determina si dos cadenas son iguales (valor 0) o cuál de las dos iría antes que la otra en función de la ordenación elegida.
substring	Devuelve un subconjunto de caracteres de la cadena.
string-length	Devuelve el número de caracteres de una cadena.
upper-case	Devuelve una cadena de caracteres convertida en mayúsculas.
lower-case	Devuelve una cadena de caracteres convertida en minúsculas.
contains	Indica si una cadena contiene o no determinado texto.
starts-width	Indica si una cadena comienza por un determinado conjunto de caracteres.
end-width	Indica si una cadena termina con un determinado conjunto de caracteres.

Ejemplos para tratar **strings**

Expresión	Resultado
//obra/titulo/string()	Todos los títulos (solo el texto) de todas las obras .
//obra/@pais/string()	Todos los valores (solo el texto) de los atributos pais de los nodos obra .
//obra/@pais/text()	Vacío. La función text() no tiene efecto sobre los atributos.
//titulo[starts-with(text(), 'S')]	Todos los títulos de las obras que comienzan por S mayúscula.
//titulo[contains(text(), 'h')]	Todos los títulos de las obras que contienen una h minúscula.
//titulo/substring(text(),1,3)	Primeros tres caracteres de cada título .
//obra/@pais/upper-case(string())	Todos los valores (solo el texto) convertidos a mayúsculas de los atributos pais de los nodos obra .
//obra/@pais/string-length(string())	Indica la longitud de los atributos pais de todos los nodos obra .

Funciones y ejemplos para **posición**

Función	Descripción
position	Proporciona la posición de un nodo en su conjunto.
last	El último nodo de un conjunto.
[posicion]	Hace referencia a la posición del nodo dentro de un conjunto.

Expresión	Resultado
//obra[1]	Primera obra de todos los nodos obra .
//obra[position()=3]	El nodo obra que se encuentra en tercera posición.
//obra[last()]	El nodo obra que se encuentra en última posición.

Funciones y ejemplos de **agregación**

Función	Descripción
count	Número de elementos.
avg	Media.
max	Valor máximo.
min	Valor mínimo.
sum	Acumulado.

Expresión	Resultado
sum(//[@anyo])	La suma de todos los valores de los atributos anyo .
max(//[@anyo])	El valor más alto de todos los atributos anyo .
avg(//[@anyo])	El valor promedio de todos los atributos anyo .

Operadores de funciones (I)

Operador	Tipo	Descripción
div	Aritmético	División.
idiv	Aritmético	División entera.
mod	Aritmético	Resto de división (módulo).
+	Aritmético	Devuelve el operando con el signo sin cambios (utilizado para conversión de tipos).
-	Aritmético	Devuelve el operando con el signo cambiado.

Operadores de funciones (II)

Operador	Tipo	Descripción
=	Lógico	Iguales.
!=	Lógico	Distintos.
>	Lógico	Mayor que.
<	Lógico	Menor que.
>=	Lógico	Mayor o igual.
<=	Lógico	Menor o igual.
and	Lógico	Y lógica.
or	Lógico	O lógica.
not	Lógico	Negación.

Ejemplos con **operadores** de funciones

Expresión	Resultado
<code>//@anyo[data()>1850]/..</code>	Todos los nodos obra cuyo atributo anyo tiene un valor superior a 1850.
<code>//@anyo[data()>1850 and data()<1880]/..</code>	Obras cuyo atributo anyo tiene como valor un número entre 1850 y 1880.
<code>//obra/titulo[text()>"N"]/string()</code>	Los títulos de la obra que empiecen por una letra mayor que "N".
<code>//obra[@anyo=1876]</code>	Selecciona los nodos obra cuyo atributo anyo tiene como valor 1876 .
<code>//obra[@anyo!=1876]</code>	Selecciona los nodos obra cuyo atributo anyo tiene como valor distinto a 1876 .
<code>//obra[@anyo<=1876]</code>	Selecciona los nodos obra cuyo atributo anyo tiene como valor un número inferior o igual a 1876 .
<code>//obra[not(@anyo=1876) and not (@anyo=1879)]</code>	Selecciona los nodos obra cuyo atributo anyo no tiene como valor 1876 ni 1879 .